계획 오류, 실행 전에 잡기

자동 검증과 재생성 루프로 보완하기

AI2-THOR · gpt-4o-mini

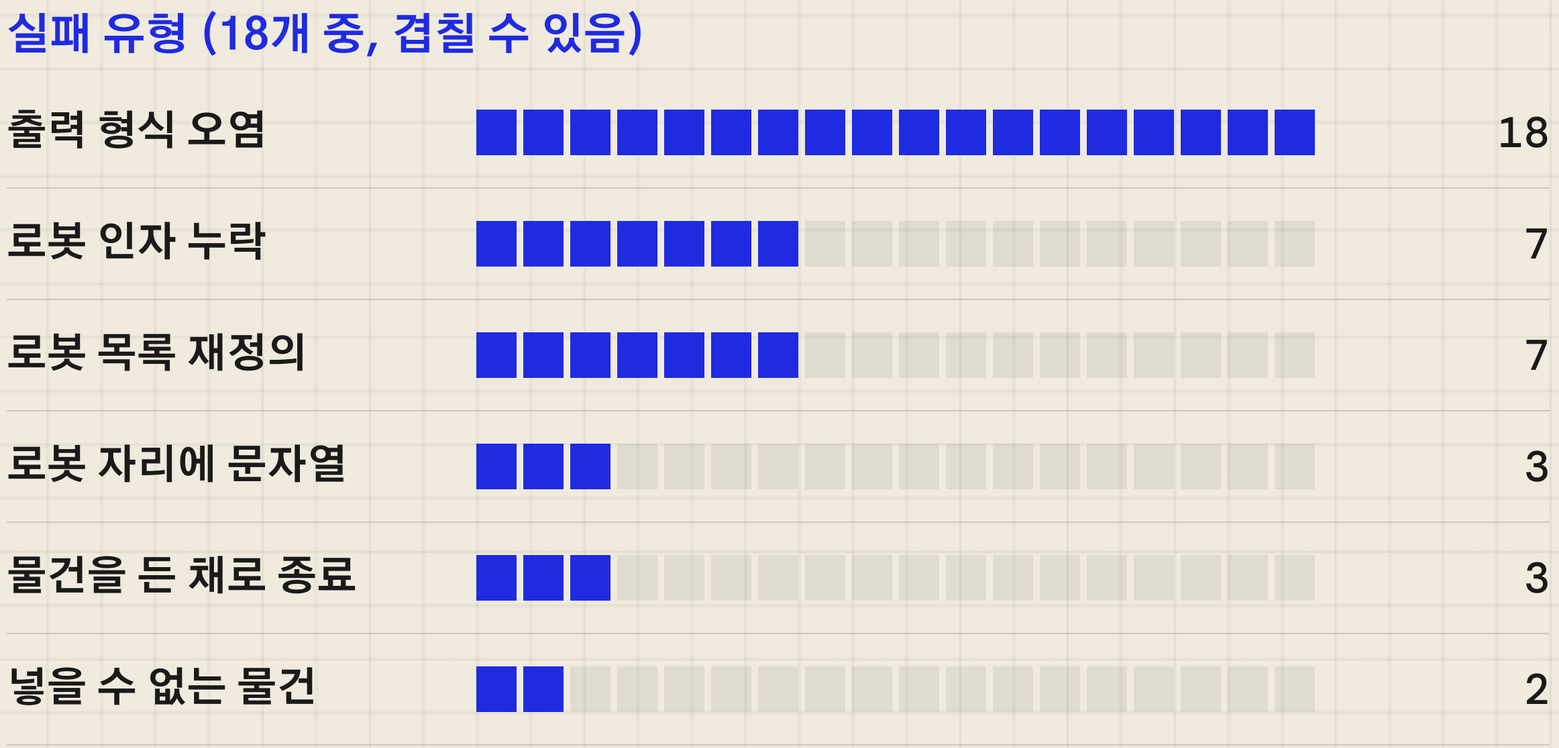
2023110224 김아림

만들어진 코드는 대부분 바로 쓸 수 없었다

3 / 18

출력 형식을 빼고
내용만 검사해도
18개 중 3개만 통과

태스크 9개 × 토큰 한도 2가지
(검증기 기준)



실행하기 전에 검사하고, 틀리면 다시 만든다

코드 생성
SMART-LLM 3단계

→

정적 검증
실행하지 않고 코드만 읽음

↑↓

재생성, 최대 3회
오류 내용을 모델에 알려 줌

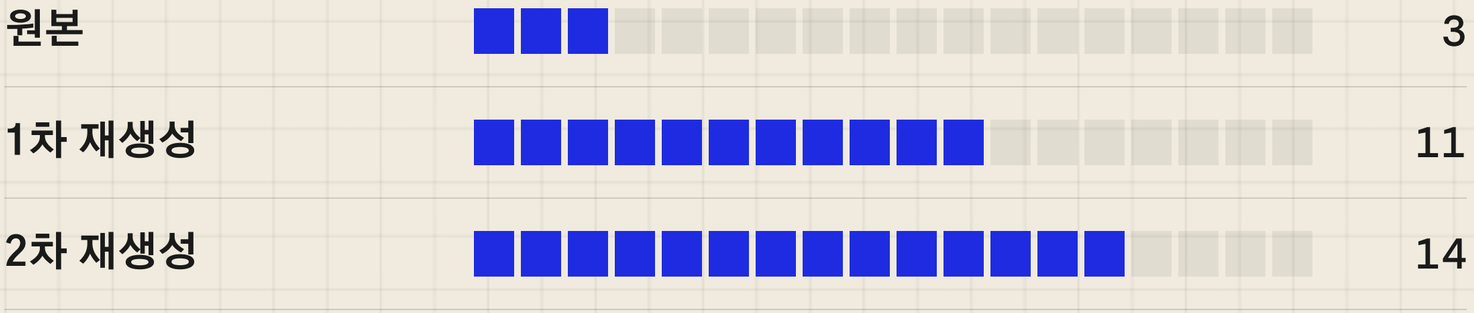
→

시뮬레이터 실행
통과한 코드만

약 1분 재생성, 태스크 9개
몇 분~수십 분 시뮬레이터, 태스크 1개

검증을 통과해도 실행에서 실패할 수 있었다

검증기 통과 (같은 규칙으로 채점, 18개 중)



검증 통과 ≠ 작업 성공

1차 코드 16개를 실행하니 5개가 실패

실패를 보고 추가한 규칙

TypeError 2개
로봇 자리에 문자열이 들어감

목표 실패 1개
상추를 든 채로 종료

목표 실패 2개
자르지 않은 빵을 토스터에 넣음

시연 1. 1차 코드는 시작하자마자 멈췄다

1차 재생성 실행 로그: Chill the apple and wash the knife (토큰 한도 1500)

```
Traceback (most recent call last):
  File "/home/arim/anaconda3/lib/python3.11/threading.py", line 1038, in _bootstrap_inner
    self.run()
  File "/home/arim/anaconda3/lib/python3.11/threading.py", line 975, in run
    self._target(*self._args, **self._kwargs)
  File "executable_plan.py", line 568, in chill_apple
    GoToObject(robot, 'Apple')
  File "executable_plan.py", line 288, in GoToObject
    robot_name = robot['name']
                 ~~~~~^^^^^^^^
TypeError: string indices must be integers, not 'str'

SR:0, TC:0, GCR:0.0, Exec:0.0, RU:1
```

원인: 1차 코드는 로봇 정보 대신 이름 글자만 넘김

```
task1_thread = threading.Thread(target=chill_apple, args=(robots[0]['name'],))
```

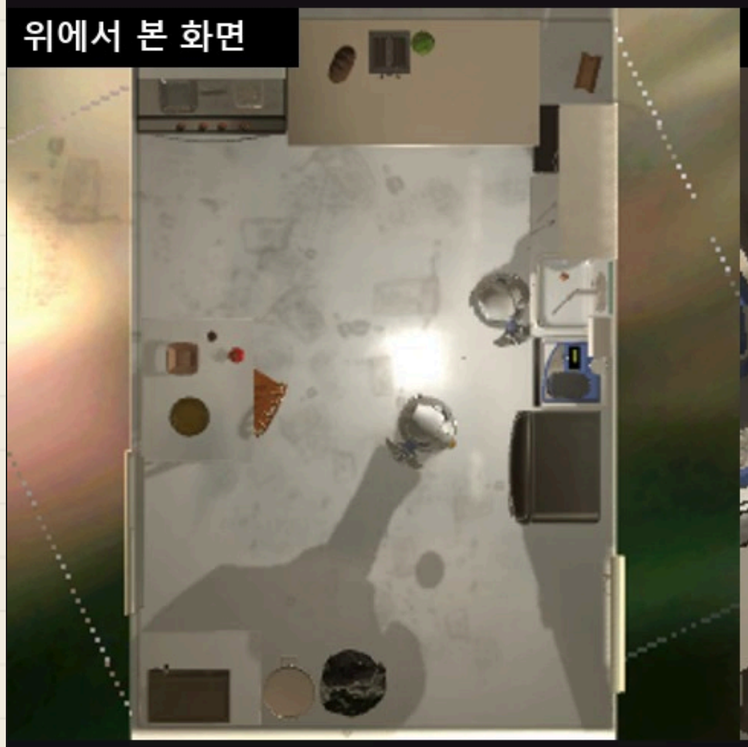
2차 재생성에서 고쳐진 코드

```
task1_thread = threading.Thread(target=chill_apple, args=(robots[0],))
```

실행 로그에서 로봇 1의 오류 부분을 발췌. 같은 오류가 로봇 2에서도 발생함

시연 2. 2차 코드는 로봇 2대가 끝까지 수행했다

로봇 2대가 동시에 일합니다: 로봇 1은 사과 넣기, 로봇 2는 칼 씻기







진행 47/61

로봇 1
사과를 들고 냉장고로 이동

로봇 2
칼을 다시 집기

영상의 한 장면 · 12개 중 대표 사례 1개 · 토큰 한도 1500 · 속도 조절함 · 칼 씻기는 점수 조건에 없음

목표 달성: 12개 중 7개에서 11개로

목표 달성 (TC 1)

7 → 11

실패 3개 → 0개
판정 불가 2개 → 1개
SR 1 5개 → 6개

판정 불가를 범위로 봐도
7~9개 vs 11~12개

	400 · 1차	400 · 2차	1500 · 1차	1500 · 2차
Put mug	달성	달성	달성	달성
Throw the Spatula	달성	달성	달성	달성
Chill the apple	달성	달성	실패	달성
Wash the fork	달성	달성	판정 불가	달성
Wash the lettuce	실패	달성	달성	달성
Slice the tomato	실패	달성	판정 불가	판정 불가

판정 불가: 제한 시간 안에 끝나지 않거나 연결이 끊겨 결과가 없음

가설은 확인되지 않았고, 대신 버그를 찾았다

가설: 토큰 한도 400 때문에 답이 잘려서 실패한다

	400	1500
답변 잘림 (9개 중)	8	0
재생성 전 통과	4	0
재생성 후 통과	8	7

잘림은 사라졌지만 통과는 늘지 않음

(조건별 1회)

버그: 태스크끼리 로봇 이름을 덮어씀

```
~~rob = robots.robots[r_id-1]~~
rob = copy.deepcopy(robots.robots[r_id-1])
```

Wash the fork	수정 전	수정 후
한도 400	4회 모두 실패	첫 시도 통과
한도 1500	4회 모두 실패	재생성 1회

이 숫자는 어디까지 믿을 수 있나

01

표본 내 결과

실패를 보고 만든 규칙을 같은 태스크에 다시 적용했다.
처음 보는 태스크에서도 효과가 있는지는 모른다.

02

작은 표본, 큰 편차

조건별 1~2회 실행. Wash the fork(1500)는 같은 코드가
한 번은 15분 초과, 한 번은 9분 51초에 끝났다.

03

TC는 작업 전체를 보지 않는다

마지막 상태만 확인한다. 12개 중 6개는 씻었는지를 확인하지 않는다.

아직 안 풀린 문제

Slice apple, Toast a slice
4번 시도해도 검증 실패

Slice the tomato (1500)
30분에도 끝나지 않음

Put two vegetables
검증 통과, 정답과 다른 재료 선택

실행 전에 잡을 수 있는 오류는 많았다

검증 통과 (18개 중)

3 → 14

시뮬레이터 목표 달성 (12개 중)

7 → 11

다음 단계 안 풀린 문제가 할당 단계 때문인지 확인하고,
LaMMA-P 기반 작업 할당을 구현해 SMART-LLM과 비교한다